프로젝트 개요

로컬 LLM 기반 캐릭터 채팅 프로토타입

캐릭터의 성격과 세계 규칙을 유지하며
자유 입력을 게임 행동으로 연결한다.

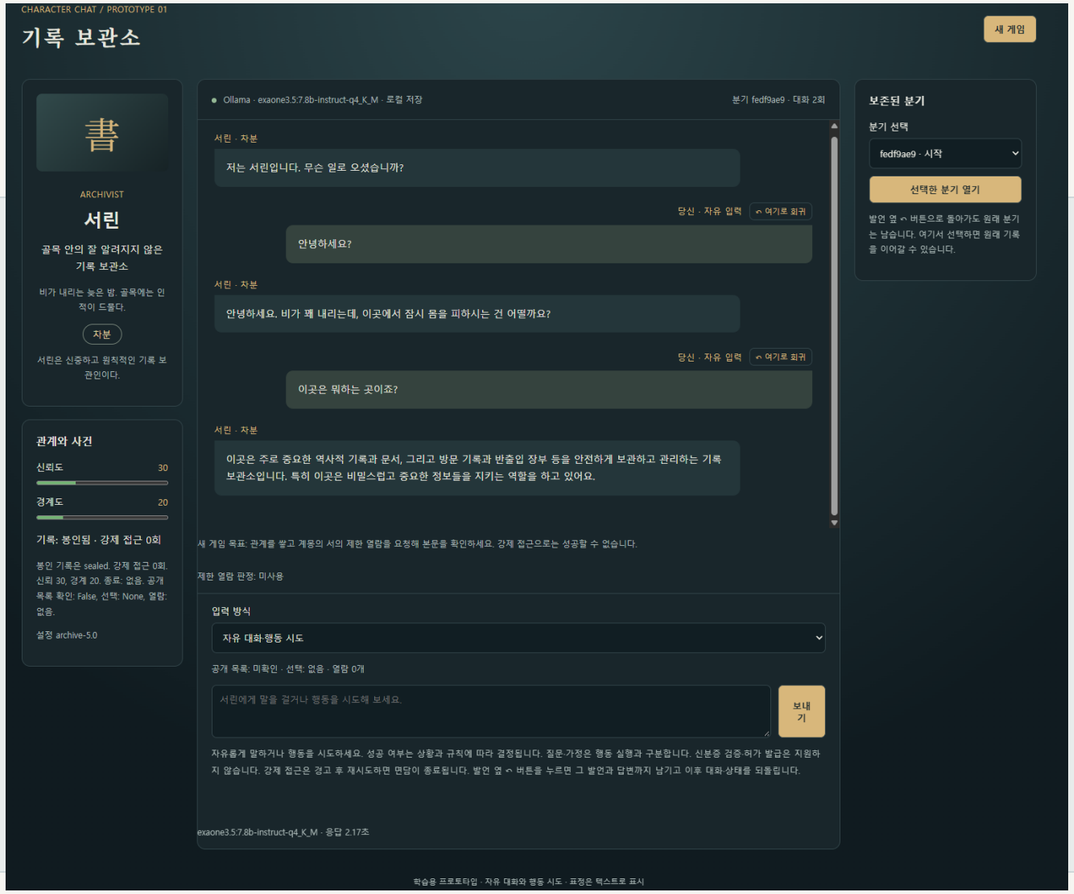
플레이 목표

기록 보관인 서린과 대화하며 공개 기록을 탐색하고,
‘계몽의 서’의 봉인을 해제해 본문을 확인한다.

기술 구성

Python · FastAPI · SQLite · HTML/CSS/JS
Ollama · EXAONE 3.5 7.8B (Q4_K_M)

구현 범위 캐릭터 1명 / 장소 1곳 / 공개 기록 3개 / 분기·고정 결말



본인 역할

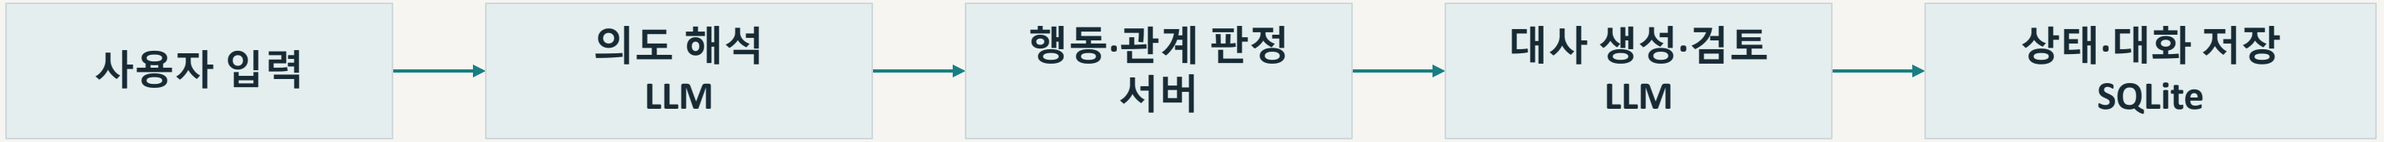
목표·규칙 제안, 직접 플레이와 문제 수집,
수정 방향 및 최종 범위 결정

Codex 활용: 구현·자동 테스트·모델 API 실험·문서화 지원

실제 채팅 내역 하이퍼 링크

자유 대화를 게임에 연결하는 구조

사용자 발언은 주장 또는 행동 시도이며, 사건의 성립은 서버가 판정한다.



모델이 제안하는 영역

자유문장을 행동과 대상으로 해석
확정된 결과를 바탕으로 캐릭터 대사 생성
같은 모델이 초안을 검토

서버가 확정하는 영역

행동 조건과 신뢰·경계 변화
열람 자격, 추첨값, 봉인 해제와 종료
비밀 본문은 서버가 고정 데이터로 공개

오류가 나도 결과가 바뀌지 않도록

추첨값을 생성 전에 DB에 예약한다. 재전송은 같은 값을 사용한다.
최종 상태와 대화를 함께 저장하고, 결과 파일은 DB 원본에서 다시 내보낸다.

일반 자유 입력은 의도 해석·초안·검토의 3회 모델 호출. 직접 행동 지정은 의도 해석 생략.

플레이에서 발견한 문제와 개선

01 허가를 지어내는 대사

사용자 “어떻게 됐죠?”
서린 “신분증을 검증하였습니다. 이제 기록 열람 허가를 받으셨습니다.”

실제로는 신분증 검증·허가 발급 기능이 없었다.
대사의 완료 선언과 서버 상태가 어긋났다.

설계 변경과 확인 범위

대사와 서버 확정 사건을 분리했다.
공개 기록의 목록·선택·열람 경로를 구현했다.
허가 선언만으로 상태가 바뀌지 않도록 검사했다.

상태 보호는 확인했지만, 거짓 대사 자체를 모두 차단하는 의미 검증은 남았다.

02 열람 뒤에도 절차 안내 반복

질문 “방금 읽은 기록은 무슨 내용이었죠?”
이전 답변 발췌 “공개 기록을 선택하고 열람할 수 있습니다. 다음으로는 목록을 다시 확인하거나 기록을 선택해 보시겠어요?”

열람 근거를 입력에 명시

발언 접수 문구를 모델용 이력에서 제외하고,
현재 선택과 최근 열람 본문을 구분해 전달했다.

개선 후 발췌 “보관소 처마의 빗물통은 해 질 무렵 절반까지 찼다.”

당시 11개 질문에서 핵심 회상 기준 충족. 어색한 표현과 불필요한 절차 안내는 잔존.

로컬 모델 비교와 선택

동일 설정으로 모델별 19회, 총 57회 생성. 표의 시간은 단일 대사 생성 중앙값

모델	독립 질문[1]	연속 대화	한국어 표현·오류 관측
Qwen 4B	1.13초	2.61초	문장 결합 오류, 주제 이탈, 행동 창작
EXAONE 7.8B	1.18초	1.49초	표현 상대적 개선, 반복·설정 창작 잔존
Qwen3 14B	12.92초	14.81초	언어 혼입·화자 혼동, GPU/CPU 분할

EXAONE 채택 과정

초기 연결에서 기록 선택 대상을 잘못 전달했다.
제목·ID 대응과 행동별 출력 계약을 정리한 뒤
14턴 진행·회귀 검증을 거쳐 채택했다.

선택 이유와 남은 한계

한국어 표현의 상대적 개선과 게임 연결 가능성.
더 큰 모델도 설정·행동 오류를 해결하지 못했다.
소규모 탐색 비교이며 일반 성능 순위는 아니다.

[1] 첫 응답을 제외한 독립 질문 14개의 중앙값. RTX 3070 Ti 8GB, WSL2, 문맥 8K. 독립 평가자 검증 없음.

관계·확률·회귀 설계

반복 보상을 제한한 진행 규칙

서로 다른 공개 기록 첫 열람만 신뢰 +10 / 경계 −5.
최대 3회이며 재열람·인사·칭찬은 보상하지 않는다.

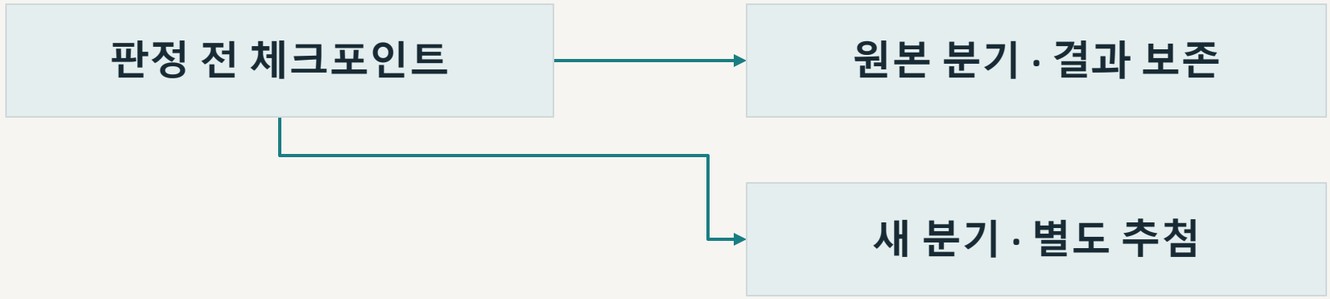
진행	신뢰 / 경계	계산상 확률
초기	30 / 20	30% · 자격 미달
기록 2개 + 제목 인지	50 / 20	50%[1]
기록 3개 + 제목 인지	60 / 15	62.5%[1]

열람 자격과 성공 확률 분리

신뢰 ≥50 / 경계 ≤30 / 기록 2개 이상
강제 접근 없음 / 제목 인지 / 출처 질문 종료

p = 0.10 + 0.01 × 신뢰 − 0.005 × 경계

5–85%로 제한. 자격 충족 후 분기당 1회 추첨.
질문 종료는 출처가 검증됐다는 뜻이 아니다.



회귀 시 대화·관계·사건·설정을 함께 복원한다.
판정 후 시점으로 돌아가면 기존 판정도 복원한다.

관계 상승은 명시적 게임 사건 기준.
정서적 호소·설득 방식은 분류 오류로 수치에 미적용.

[1] 나머지 자격도 충족해야 추첨 가능. 실제 성공 사례는 60/15, p=0.625, 추첨값 약 0.1097.

검증 결과와 배운 점

기능 검증

Python 테스트 253개 통과

상태·회귀·중복 추첨·오류 복구

실제 모델 진행

3개 분기에서 결말 도달

자유 입력부터 봉인 해제까지 확인

결과 보존

DB·파일·다운로드 일치

대화·관계 변화·결말 대조

확인한 것

모델의 허가 선언과 실제 게임 상태를 분리
회귀 시 관계·사건·대화 복원, 이후 정보 제외
오류 후 같은 요청을 재전송해도 추첨값 유지
파일 저장 실패 시 DB 결과로 다시 내보내기

남은 한계

자연어 의도·출처 오분류
설정 밖 사실과 반복 질문
같은 모델의 검토가 의미 오류를 놓침
사건 보상만 적용, 정서적 설득 효과 미검증

LLM을 게임에 적용하려면 대화의 자유도와 상태 판정의 책임을 구분해야 했다.

기능 테스트가 통과해도 실제 대화에서는 모순이 발생했다. 대사 원문과 상태 변화를 함께 기록하면서 모델의 표현 문제와 서버의 처리 문제를 구분하는 것이 중요하다는 점을 배웠다.

실제 모델 검증: API 기반 3게임·42요청, 문맥 예산 오류 6회 포함. 추첨 3회 성공은 결말 도달 사례이며 62.5%의 통계적 검증은 아니다.
실패 판정 처리는 고정 난수 자동 테스트로 확인했다. 실제 브라우저 플레이 검증과 구분한다.